Analiza skupa Bank Customer Survey – Marketing for Term Deposit metodom klasifikacije

Tamara Ivanović, 462/2018

Seminarski rad u okviru kursa Istraživanje podataka 1 Matematički fakultet

Avgust, 2019.

Uvod

- Klasifikacija skupa bank marketing term deposit
- Analiza i pretprocesiranje
- Klasifikacija u SPSS modeleru
- Klasifikacija u Pythonu
- Analiza dobijenih modela

Lista atributa

- age godine klijenta
- job –zanimanje klijenta, kategoički atribut (12 kategorija, uključujući unknown)
- marital bračno stanje, kategorički atribut (married, single, divorced)
- education nivo obrazovanja, kategorički atribut(primary, secondary, tertiary, unknown)
- . default da li klijent ima neotplaćeni kredit (da li ima dug), binarni atribut (yes, no)
- balance prosečna godišnja zarada u evrima
- housing da li klijent ima stambeni kredit, binarni atribut (yes, no)
- loan da li klijent ima lični zajam, binarni atribut (yes, no)
- contact način na koji je klijent kontaktiran, kategorički atribut (unknown, telephone, cellular)
- day poslednji dan kada je klijent kontaktiran, numerički atribut
- month mesec u kom je klijent poslednji put kontaktiran, katetorički atribut (jan, feb, ..., nov, dec)
- duration dužina tog razgovora u sekundama, numerički atribut
- campaign koliko puta je ovaj klijent kontaktiran tokom ove kampanje, uključujući poslednji razgovor
- pdays broj dana koji je protekao između prethodne i ove kampanje za datog klijenta (-1
 ukoliko je klijent prvi put kontaktiran)
- previuous broj poziva upućenih klijentu pre ove kampanje
- poutcome ishod prethodne marketinške kampanje, kategorički atribut (unknown, other, failure, success)
- y da li se klijent prijavio za oročeni depozit, binarni atribut (0, 1)

Slika 1: Atributi skupa

Pretprocesiranje u Python-u

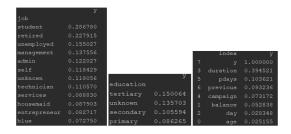
- Nema null vrednosti
- unknown zamenjeno kod education i job
- Uklonjeni atributi poutcome, contact i day
- MinMaxScaler(), train test split()



Slika 2: Prosečne vrednosti atributa

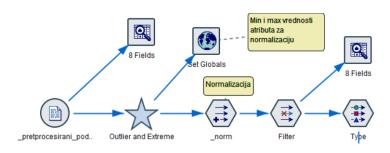
• duration, pdays, previous, campaign, balance, job, education

Pretprocesiranje u Python-u



Slika 3: Korelacije atributa

Pretprocesiranje u SPSS modeleru



Slika 4: Shema pretprocesiranje u SPSS modeleru

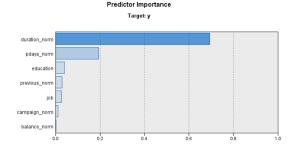
Uvod Analiza i pretprocesiranje Klasifikacija Zaključak C5.0 CART KNN QUEST Bajesove mreže Naivan Bajesov algoritam

Klasifikacija

- C5.0
- CART
- KNN
- QUEST
- Bajesove mreže
- Naivan Bajesov algoritam

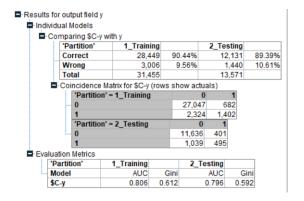
C5.0

- Drvo odlučivanja
- Tendencija je preciznost
- Dubina 13



Slika 5: Algoritam C5.0 - Važnost prediktora

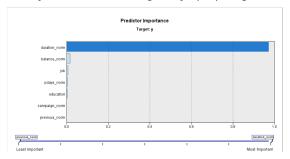
C5.0



Slika 6: Algoritam C5.0 - Matrica konfuzije

CART

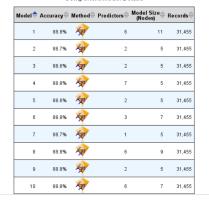
- Minimalna dubina stabla: 4
- Ginijev indeks
- Bolja stabilnost Enhance model stability
- Potrkesivanje stabla radi izbegavanja preprilagođenosti



Slika 7: Algoritam CART - Važnost prediktora

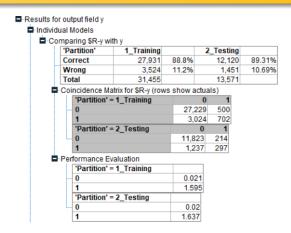
CART

Component Model Details



Slika 8: Algoritam CART - Modeli

CART



Slika 9: Algoritam CART - Matrica konfuzije

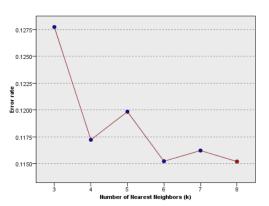
KNN

- Cilj: Preciznost modela
- k između 3 i 8
- Menhetn rastojanje
- Prediktori jednako važni
- Za k=6 i k=8 najbolja rešenja

Uvod Analiza i pretprocesiranje Klasifikacija Zaključak C5.0 CART KNN QUEST Bajesove mreže Naivan Bajesov algoritam

KNN

k Selection Error log



Slika 10: Algoritam KNN - Nivo greške u zavisnosti od k

KNN

Results for output field y

Individual Models

| Ġ-C | omparing \$KNN- | y with y | | | |
|-----|-----------------|------------|--------|-----------|--------|
| | 'Partition' | 1_Training | | 2_Testing | |
| | Correct | 28,339 | 90.09% | 12,235 | 90.16% |
| | Wrong | 3,116 | 9.91% | 1,336 | 9.84% |
| | Total | 31.455 | | 13 571 | |

Coincidence Matrix for \$KNN-y (rows show actuals)

Confidence Values Report for \$KNNP-y

| ь. | Ev | alı | rat | ion | B/A | otr | ice |
|----|----|-----|-----|------|-----|-----|-----|
| | Lv | an | Jai | 1011 | IV | Cu | IUS |
| | | | | | | | |

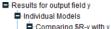
| Ī | 'Partition' | 1_Training | | 2_Testing | |
|---|-------------|------------|-------|-----------|-------|
| | Model | AUC | Gini | AUC | Gini |
| | \$KNN-y | 0.916 | 0.831 | 0.917 | 0.834 |

Slika 11: Algoritam KNN - Matrica konfuzije

QUEST

- Binarno stablo
- Uvek dubina 2
- duration najbitniji
- Ostali prediktori jednako važni, ali zanemarljivi
- AUC = 0.637, blizu 0.5

QUEST



| 'Partition' | 1_Training | | 2_Testing | |
|-------------|------------|--------|-----------|--------|
| Correct | 27,929 | 88.79% | 12,123 | 89.33% |
| Wrong | 3,526 | 11.21% | 1,448 | 10.67% |
| Total | 31,455 | | 13,571 | |

- Coincidence Matrix for \$R-v (rows show actuals)
- Performance Evaluation
- Confidence Values Report for \$RC-y

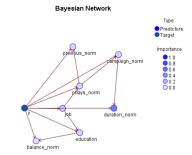
- Evaluation Metrics

| | 'Partition' | 1_Training | | 2_Testing | |
|---|-------------|------------|-------|-----------|-------|
| L | Model | AUC | Gini | AUC | Gini |
| | \$R-y | 0.637 | 0.275 | 0.645 | 0.289 |

Slika 12: Algoritam QUEST - Matrica konfuzije

QUEST

- Bajesova statistika
- Posmatra duration, zatim job
- Uslovne verovatnoće svake instance



Slika 13: Algoritam Bajesove mreže

Bajesove mreže

- Results for output field v
 - ☐ Individual Models
 - -Comparing \$B-y with y

| 'Partition' | 1_Training | | 2_Testing | |
|-------------|------------|--------|-----------|-------|
| Correct | 27,981 | 88.96% | 12,106 | 89.2% |
| Wrong | 3,474 | 11.04% | 1,465 | 10.8% |
| Total | 31,455 | | 13,571 | |

- Coincidence Matrix for \$B-y (rows show actuals)
- Performance Evaluation
- Confidence Values Report for \$BP-y
- Evaluation Metrics

| Ī | 'Partition' | 1_Training | | 2_Testing | |
|---|-------------|------------|-------|-----------|-------|
| | Model | AUC | Gini | AUC | Gini |
| | \$B-y | 0.859 | 0.718 | 0.852 | 0.703 |

Slika 14: Algoritam Bajesove mreže - Matrica konfuzije

Naivan Bajesov algoritam

- trening skup 0,75, test skup 0,25
- 1-yes, 0-no
- sklearn.naive_bayes
- Gausova formula

Naivan Bajesov algoritam

Slika 15: Naivan Bajesov algoritam - Matrica konfuzije

Zaključak

| Algoritam | Trening skup | Test skup |
|----------------|--------------|-----------|
| C5.0 | 90.44 | 89.39 |
| CART | 88.80 | 89.31 |
| KNN | 90.09 | 90.16 |
| QUEST | 88.79 | 89.33 |
| Bajesova mreža | 88.96 | 89.20 |
| Naivni Bajes | - | 87.24 |

Slika 16: Preciznost algoritama

Uvod Analiza i pretprocesiranje Klasifikacija **Za**ključak

Hvala na pažnji!