Analiza skupa Bank Customer Survey – Marketing for Term Deposit metodom klasifikacije

Tamara Ivanović, 462/2018

Seminarski rad u okviru kursa Istraživanje podataka 1 Matematički fakultet

Avgust, 2019.

Uvod

- Klasifikacija skupa bank marketing term deposit
- Analiza i pretprocesiranje
- Klasifikacija u SPSS modeleru
- Klasifikacija u Pythonu
- Analiza dobijenih modela

Lista atributa

- age godine klijenta
- job –zanimanje klijenta, kategoički atribut (12 kategorija, uključujući unknown)
- marital bračno stanje, kategorički atribut (married, single, divorced)
- education nivo obrazovanja, kategorički atribut(primary, secondary, tertiary, unknown)
- . default da li klijent ima neotplaćeni kredit (da li ima dug), binarni atribut (yes, no)
- balance prosečna godišnja zarada u evrima
- housing da li klijent ima stambeni kredit, binarni atribut (yes, no)
- loan da li klijent ima lični zajam, binarni atribut (yes, no)
- contact način na koji je klijent kontaktiran, kategorički atribut (unknown, telephone, cellular)
- day poslednji dan kada je klijent kontaktiran, numerički atribut
- month mesec u kom je klijent poslednji put kontaktiran, katetorički atribut (jan, feb, ..., nov, dec)
- duration dužina tog razgovora u sekundama, numerički atribut
- campaign koliko puta je ovaj klijent kontaktiran tokom ove kampanje, uključujući poslednji razgovor
- pdays broj dana koji je protekao između prethodne i ove kampanje za datog klijenta (-1
 ukoliko je klijent prvi put kontaktiran)
- previuous broj poziva upućenih klijentu pre ove kampanje
- poutcome ishod prethodne marketinške kampanje, kategorički atribut (unknown, other, failure, success)
- y da li se klijent prijavio za oročeni depozit, binarni atribut (0, 1)

Slika 1: Atributi skupa

Pretprocesiranje u Python-u

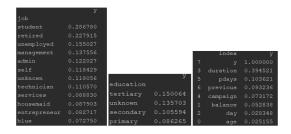
- Nema null vrednosti
- unknown zamenjeno kod education i job
- Uklonjeni atributi poutcome, contact i day
- MinMaxScaler(), train test split()



Slika 2: Prosečne vrednosti atributa

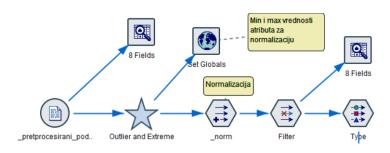
• duration, pdays, previous, campaign, balance, job, education

Pretprocesiranje u Python-u



Slika 3: Korelacije atributa

Pretprocesiranje u SPSS modeleru



Slika 4: Shema pretprocesiranje u SPSS modeleru

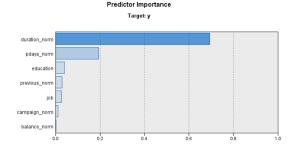
Uvod Analiza i pretprocesiranje Klasifikacija Zaključak C5.0 CART KNN QUEST Bajesove mreže Naivan Bajesov algoritam

Klasifikacija

- C5.0
- CART
- KNN
- QUEST
- Bajesove mreže
- Naivan Bajesov algoritam

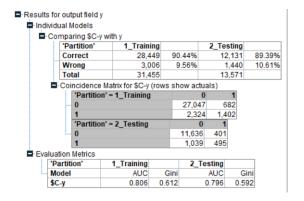
C5.0

- Drvo odlučivanja
- Tendencija je preciznost
- Dubina 13



Slika 5: Algoritam C5.0 - Važnost prediktora

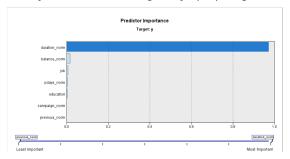
C5.0



Slika 6: Algoritam C5.0 - Matrica konfuzije

CART

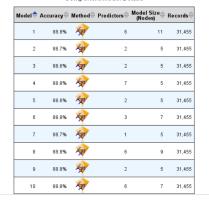
- Minimalna dubina stabla: 4
- Ginijev indeks
- Bolja stabilnost Enhance model stability
- Potrkesivanje stabla radi izbegavanja preprilagođenosti



Slika 7: Algoritam CART - Važnost prediktora

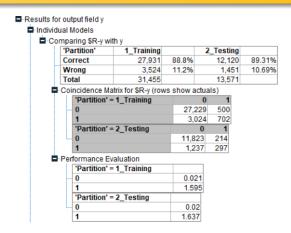
CART

Component Model Details



Slika 8: Algoritam CART - Modeli

CART



Slika 9: Algoritam CART - Matrica konfuzije

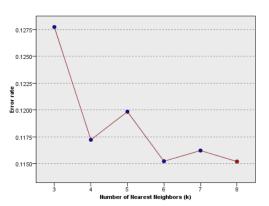
KNN

- Cilj: Preciznost modela
- k između 3 i 8
- Menhetn rastojanje
- Prediktori jednako važni
- Za k=6 i k=8 najbolja rešenja

Uvod Analiza i pretprocesiranje Klasifikacija Zaključak C5.0 CART KNN QUEST Bajesove mreže Naivan Bajesov algoritam

KNN

k Selection Error log



Slika 10: Algoritam KNN - Nivo greške u zavisnosti od k

KNN

Results for output field y

Individual Models

Ġ-C	omparing \$KNN-	y with y			
	'Partition'	1_Training		2_Testing	
	Correct	28,339	90.09%	12,235	90.16%
	Wrong	3,116	9.91%	1,336	9.84%
	Total	31.455		13 571	

Coincidence Matrix for \$KNN-y (rows show actuals)

Confidence Values Report for \$KNNP-y

ь.	Ev	alı	rat	ion	B/A	otr	ice
	Lv	an	Jai	1011	IV	Cu	IUS

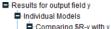
Ī	'Partition'	1_Training		2_Testing	
	Model	AUC	Gini	AUC	Gini
	\$KNN-y	0.916	0.831	0.917	0.834

Slika 11: Algoritam KNN - Matrica konfuzije

QUEST

- Binarno stablo
- Uvek dubina 2
- duration najbitniji
- Ostali prediktori jednako važni, ali zanemarljivi
- AUC = 0.637, blizu 0.5

QUEST



'Partition'	1_Training		2_Testing	
Correct	27,929	88.79%	12,123	89.33%
Wrong	3,526	11.21%	1,448	10.67%
Total	31,455		13,571	

- Coincidence Matrix for \$R-v (rows show actuals)
- Performance Evaluation
- Confidence Values Report for \$RC-y

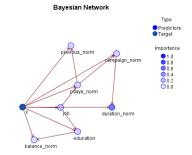
- Evaluation Metrics

	'Partition'	1_Training		2_Testing	
L	Model	AUC	Gini	AUC	Gini
	\$R-y	0.637	0.275	0.645	0.289

Slika 12: Algoritam QUEST - Matrica konfuzije

Bajesove mreže

- Bajesova statistika
- Posmatra duration, zatim job
- Uslovne verovatnoće svake instance



Slika 13: Algoritam Bajesove mreže

Bajesove mreže

- Results for output field v
 - ☐ Individual Models
 - -Comparing \$B-y with y

'Partition'	1_Training		2_Testing	
Correct	27,981	88.96%	12,106	89.2%
Wrong	3,474	11.04%	1,465	10.8%
Total	31,455		13,571	

- Coincidence Matrix for \$B-y (rows show actuals)
- Performance Evaluation
- Confidence Values Report for \$BP-y
- Evaluation Metrics

Ī	'Partition'	1_Training		2_Testing	
	Model	AUC	Gini	AUC	Gini
	\$B-y	0.859	0.718	0.852	0.703

Slika 14: Algoritam Bajesove mreže - Matrica konfuzije

Naivan Bajesov algoritam

- trening skup 0,75, test skup 0,25
- 1-yes, 0-no
- sklearn.naive_bayes
- Gausova formula

Naivan Bajesov algoritam

Slika 15: Naivan Bajesov algoritam - Matrica konfuzije

Zaključak

Algoritam	Trening skup	Test skup
C5.0	90.44	89.39
CART	88.80	89.31
KNN	90.09	90.16
QUEST	88.79	89.33
Bajesova mreža	88.96	89.20
Naivni Bajes	-	87.24

Slika 16: Preciznost algoritama

Uvod Analiza i pretprocesiranje Klasifikacija **Za**ključak

Hvala na pažnji!